Estimação de Parâmetros

Análise de Dados em Física de Altas Energias

Marco Dias

2026

Distribuições contínuas

Uma função densidade de probabilidade $f(x)$ deve satisfazer

$$f(x) \geq 0, \qquad \int_{-\infty}^{+\infty} f(x)\, dx = 1.$$

A probabilidade de observar x no intervalo $[a, b]$ é

$$P(a \leq x \leq b) = \int_a^b f(x)\, dx.$$

- A variável x possui valores contínuos.
- A probabilidade de um ponto isolado é nula:

$$P(x = x_0) = 0.$$

- Em um histograma, a previsão para um bin i é aproximadamente

$$N_i^{\text{pred}} = N \int_{x_i}^{x_{i+1}} f(x)\, dx.$$

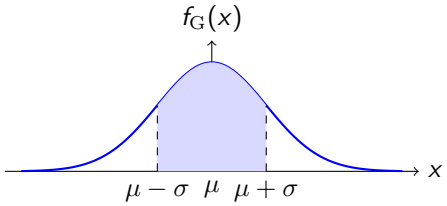
Interpretação

3. Distribuição Normal ou Gaussiana

A distribuição Gaussiana é

$$f_{\mathrm{G}}(x;\mu,\sigma) = \frac{1}{\sqrt{2\pi}\sigma}\exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right], \qquad \sigma > 0.$$

- μ: valor central ou média;
- σ: desvio padrão;
- aproximadamente 68.27% dos eventos estão em $[\mu-\sigma, \mu+\sigma]$;
- aproximadamente 95.45% estão em $[\mu-2\sigma, \mu+2\sigma]$.

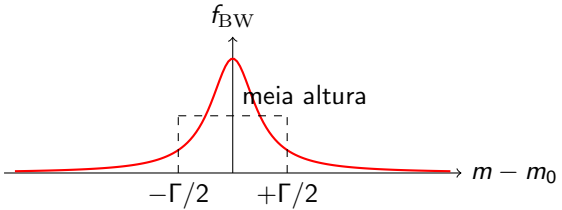


4. Distribuição de Breit–Wigner

Para uma ressonância de massa m_0 e largura Γ, usa-se

$$f_{\mathrm{BW}}(m; m_0, \Gamma) = \frac{1}{2\pi} \frac{\Gamma}{(m - m_0)^2 + \Gamma^2/4}.$$

- m_0: posição da ressonância;
- Γ é a largura a meia altura, quando a função é escrita na forma acima;
- a largura relaciona-se ao tempo de vida por $\tau \simeq \frac{\hbar}{\Gamma}$.



Teorema Central do Limite

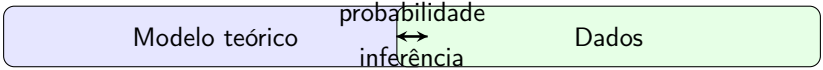
Se $X_1, X_2, \ldots X_n$ são variáveis aleatórias independentes e identicamente distribuídas, com média μ finita e variância σ^2 finita, então a soma (ou média) padronizada

$$Z_n = \frac{\hat{X}_b - \mu}{\sigma/\sqrt{n}},$$

converge em distribuição para uma Normal(0, 1) quando $n \to \infty$ **independentemente da distribuição original de X**. É por isso que ruídos de medida resultantes de muitas pequenas contribuições independentes tendem a ser aproximadamente gaussianos, e é a base teórica para intervalos de confiança construídos com a distribuição normal mesmo quando os dados individuais não são gaussianos.

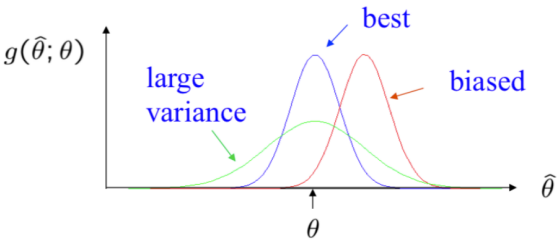
O Problema da Estimação

- O experimento amostra a realidade, onde obtemos uma amostra de dados $\mathrm{x} = (x_1, x_2, \ldots, x_N)$.
- A teoria descreve a física através de PDFs que dependem de parâmetros desconhecidos $\Theta_{\mathrm{true}} = (m_H, \Gamma_H, \ldots, \sigma)$.
- Exemplo: $f(x;\theta) = \frac{1}{\theta} e^{-x/\theta}$, onde x são os dados medidos e θ é o parâmetro a estimar.
- Objetivo: encontrar uma função dos dados $\hat{\theta}(\mathrm{x})$ que estime o parâmetro.
- Chamamos esse procedimento de **ajuste de parâmetros** (parameter fitting).



Propriedades dos Estimadores

- **Consistente**: Converge para o valor verdadeiro com mais dados $\hat{\theta} \to \theta^{\text{true}}$, se o número de amostras for grande.
- **Não-enviesado**: A diferença entre o valor esperado do estimador e o valor verdadeiro chamas-se **bias** $b = E(\hat{\theta}) - \theta^{\text{true}} = 0$.
- **Eficiente**: Variância pequena.
- **Robusto**: Insensível a desvios das suposições da PDF.



Abordagem Bayseana da Probabilidade

- **Teorema de Bayes:** A probabilidade condicional de ocorrer o evento A dado que B ocorreu é

$$P(A|B) = \frac{P(A \cap B}{P(B)},$$

como $P(B|A) = \frac{P(A \cap B}{P(A)}$, podemos deduzir que

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}.$$

- A probabilidade P(A) pode ser interpretada como a probabilidade do evento A **antes** do conhecimento que evento B aconteceu (priori) , enquanto $P(A|B)$ é a probabilidade conhecendo que B aconteceu (posteriori).
- O termo $P(B)$ pode ser considerado um fator de normalização. O espaço de amostras $\Omega = \bigcup_{i=1}^{N} A_i$ e

$$P(B) = \sum_{i=1}^{N} P(B|A_i)P(A_i).$$

Abordagem Bayseana da Probabilidade

- Dada uma amostra $(x_1, \ldots, x_N)$ cujas FDP são conhecidadas que depende de m parâmetros $\theta_1, \ldots, \theta_m)$ definimos

$$L(x_1, \ldots, x_N|\theta_1, \ldots, \theta_m) = \left.\frac{dP(x_1, \ldots, x_N)}{dx_1 \ldots dx_N}\right|_{\theta_1, \ldots, \theta_m},$$

  como a **Likelihood function**.
- Análogamente

$$P(\theta_1, \ldots, \theta_m|x_1, \ldots, x_N) = \frac{L(x_1, \ldots, x_N|\theta_1, \ldots, \theta_m)\pi(\theta_1, \ldots, \theta_m)}{\int L(x_1, \ldots, x_N|\theta'_1, \ldots, \theta_m)d\theta'_1 \ldots d\theta'_m},$$

  onde a probabilidade $\pi(\theta_1, \ldots, \theta_m)$ é o prior . O denominador é um fator de normalização.
- O uso repetido da função Likelihood define um processo de aprendizagem para o cálculo de probabilidade:

$$L(x_1, x_2|\theta) = L(x_1|\theta)L(x_2|\theta) \Rightarrow P_2(\theta) \propto \underbrace{P_0(\theta)}_{\pi(\theta)} L(x_1, x_2|\theta)$$

Exemplo: Contagem de Jets (b-tagging)

Problema: Em um evento com n_b jets b verdadeiros e n_{light} jets leves, qual a probabilidade de encontrar n_{tag} jets marcados?

- Eficiência de marcar b-jets: $\epsilon_b = 68\%$
- Taxa de erro (mistag) para jets leves: $\epsilon_{\text{mistag}} = 1\%$
- Processo: $ttH \to bl\nu l + bqq' + bb$ (4 b-jets + 2 jets leves)

Solução via PyROOT (Binomial):

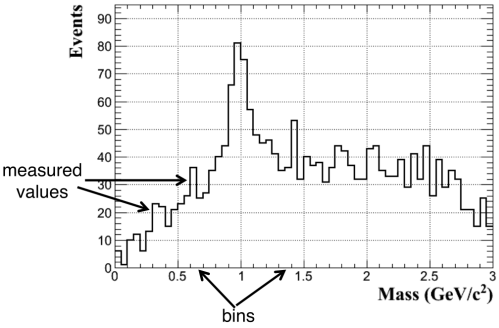
```
import ROOT
from ROOT import TMath

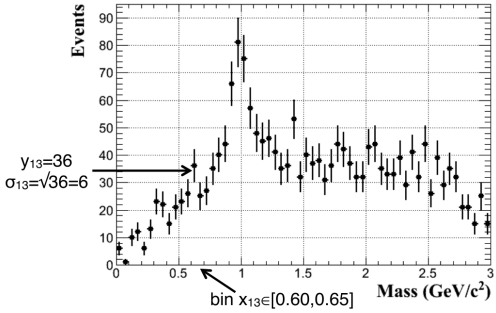
# Funcao de probabilidade binomial
def prob_binomial(n, k, p):
    return TMath.Binomial(n, k) * (p**k) * ((1-p)**(n-k))

# Exemplo: Probabilidade de marcar 4 jets b (de 4 possiveis)
n_b = 4
k = 4
eff_b = 0.68
prob = prob_binomial(n_b, k, eff_b)
print(f"Probabilidade de marcar {k} b-jets: {prob:.4f}")
```

Histogramas e Incertezas Estatísticas

- Em experimentos de contagem, representamos os dados em histogramas.
- Cada bin tem uma incerteza de Poisson: $\sigma_i = \sqrt{y_i}$.
- Exemplo: Bin com 36 eventos tem $\sigma = \sqrt{36} = 6$.





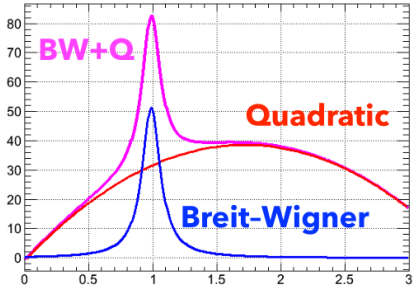
O Modelo Teórico

- Precisamos de uma PDF teórica $f(x_i; \theta^{\text{true}})$ para ajustar os dados.
- Exemplo: Sinal (Breit-Wigner) + Background (Quadrática).

$$BW(x; D, \Gamma, M) \approx \frac{D\Gamma}{(x^2 - M^2)^2 + 0.25\Gamma^2}$$

$$Q(x; A, B, C) = A + Bx + Cx^2$$

$$f(x_i; \theta) = BW(x_i; D, \Gamma, M) + Q(x_i; A, B, C)$$



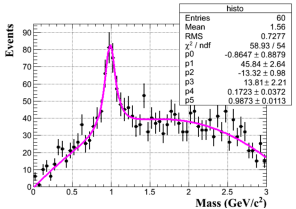
Ajuste de Histograma com PyROOT

```python
import ROOT

# Criar histograma de exemplo
h = ROOT.TH1F("h", "Mass;Mass [GeV];Events", 100, 0, 3)
# ... preencher histograma com dados ...

# Definir funcao de ajuste (Breit-Wigner + Quadratica)
fit_func = ROOT.TF1("fit_func",
    "[0]*[1]/((x*x-[2]*[2])**2 + 0.25*[1]*[1]) + [3] + [4]*x + [5]*x*x",
    0, 3)
fit_func.SetParameters(1, 0.1, 1.0, 10, 0, 0) # Chutes iniciais

# Realizar o ajuste
h.Fit(fit_func, "R")
print(f"Chi2/ndf: {fit_func.GetChisquare()}/{fit_func.GetNDF()}")
```



Método da Máxima Verossimilhança (ML)

- Assume que as observações são independentes.
- Função de Verossimilhança: $L(\mathrm{x};\theta) = \prod_{i=1}^{N} f(x_i;\theta)$.
- O estimador $\hat{\theta}_{ML}$ é o valor que maximiza L.
- Na prática, minimizamos $-\ln L$ ou $-2\ln L$.
- Equações de verossimilhança: $\frac{\partial \ln L}{\partial \theta_j} = 0$.

Exemplo: Tempo de Vida

$f(t;\tau) = \frac{1}{\tau} e^{-t/\tau} \implies \ln L(\tau) = \sum(\ln \frac{1}{\tau} - \frac{t_i}{\tau}) \implies \hat{\tau} = \frac{1}{N}\sum t_i$

ML com PyROOT (RooFit)

```
import ROOT
from ROOT import RooFit

# Variavel observavel
x = ROOT.RooRealVar("x", "x", 0, 10)
# Parametro a estimar
tau = ROOT.RooRealVar("tau", "tau", 1.0, 0.1, 10.0)
# PDF
pdf = ROOT.RooExponential("pdf", "pdf", x, tau)

# Gerar dados (ou carregar dados reais)
data = pdf.generate(ROOT.RooArgSet(x), 1000)

# Ajuste de Maxima Verossimilhanca
pdf.fitTo(data)
tau.Print()
```

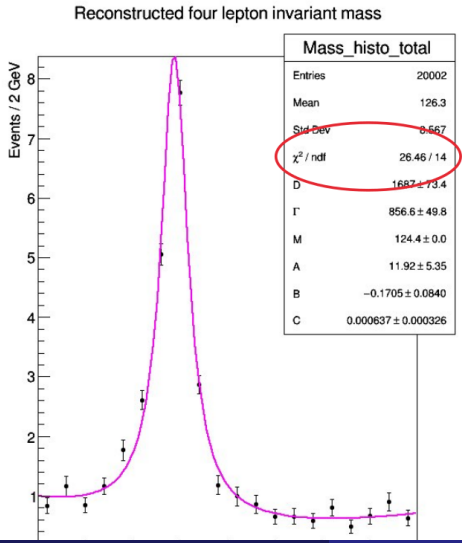
Método dos Mínimos Quadrados (χ^2)

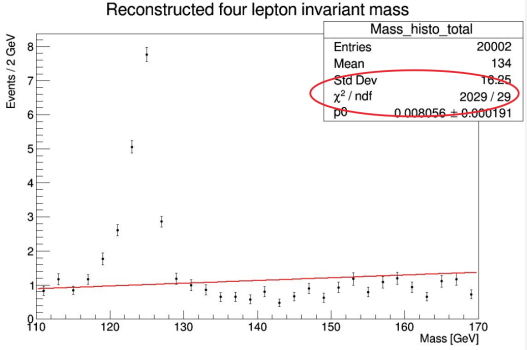
- Usado quando temos valores precisos de x_i e medidas y_i com incertezas σ_i.
- Minimizamos a soma ponderada dos quadrados das diferenças:

$$\chi^2(\theta) = \sum_{i=1}^{N} \frac{(y_i - f(x_i;\theta))^2}{\sigma_i^2}$$

- O estimador é encontrado minimizando χ^2: $\frac{\partial \chi^2}{\partial \theta} = 0$.
- Qualidade do ajuste: $\chi^2/\text{NDOF} \approx 1$.

Exemplo de Bom e Mau Ajuste





Mau ajuste: $\chi^2/\text{ndf} = 2029/...$

Mínimos Quadrados com PyROOT

```
import ROOT

# Criar grafico de dispersao (TGraphErrors)
# x, y, ex, ey
graph = ROOT.TGraphErrors(5, x_array, y_array, ex_array, ey_array)

# Definir funcao de ajuste (polinomio de 1o grau)
f = ROOT.TF1("f", "[0] + [1]*x", 0, 6)
f.SetParameters(1, 1)

# Ajuste por minimos quadrados
graph.Fit(f, "S") # "S" para salvar o resultado
print(f"Chi2/ndf: {f.GetChisquare()}/{f.GetNDF()}")
print(f"Parametro 0: {f.GetParameter(0)} +/- {f.GetParError(0)}")
```

Likelihood Estendida

- Quando o número de eventos N é uma variável aleatória de Poisson com média ν.
- Seja $x = (x_1, \ldots, x_N)$. A Função de verossimilhança estendida:

$$L(\nu; \theta) = \frac{\nu^N e^{-\nu}}{N!} \prod_{i=1}^{N} f(x_i; \theta)$$

- Se $\nu = \nu(\theta)$, então:

$$\ln L(\theta) = -\nu(\theta) + \sum_{i=1}^{N} \ln(\nu(\theta) f(x_i; \theta)) + C$$

Maximizamos $\ln L$ para obter os parâmetros.